

這兩題有一個很大的優點：它們不是把課本搬到網頁上，而是利用 HTML 的互動性回答紙本很難直觀看出的問題。而且兩題還能形成一條完整的學習路徑：

Matrix $\rightarrow$ Linear Transformation $\rightarrow \det A \rightarrow$ Area / Singularity $\rightarrow \det(A - \lambda$

以你最近正在讀的矩陣內容來說，這一組也剛好會把 **determinant**、**singular matrix**、**linear dependence**、**rank**、**eigenvector** 幾個目前容易各自分開的概念串在一起。

昨天 下午8:56



G. L. Squires - Practica...
PDF

我在想我要不要做一個專屬物理學家的AI skill 或說gem。主要問題是想解決AI對話時可能會漏掉的一些共識。做為一個科學家，我們專注的不只速度，對於語言的表達常常不是很清楚(尤其是還不清楚這個現象的原理時)，如何觀察理解這些現象，一級如何系統化地描述這個現象就是科學家的任務之一。對於一個大語言模型，如果依照這本書的歸類其實不算是一個科學家，他只完成了理論的理解和一些特殊情況的窮舉(尤其是網路上無窮的資料)，他可以說是一個全世界最強的物理學家。但是，這個能力常常無法被激發，原因有以下：1. LLM不只需要解決科學問題，對於語言模型而言，或許重要的不是真理，重要的是我如何完美的回答詢問者的

顯示更多

處理時間為 7s

我覺得你現在描述的東西，比「專屬物理學家的 AI」更精確的定位其實是「讓 LLM 採用實驗物理學家的認識論與工作流程」。這個差異很重要。

因為你真正想解決的，似乎不是「AI 不會物理」。恰恰相反，你的前提是：LLM 已經知道非常大量的理論、公式、典型案例與文獻模式。真正的問題是：

當使用者帶著一個不完整、含糊、甚至描述錯誤的真實現象來問 AI 時，AI 太容易直接進入「回答問題」模式，而不是先進入「建立問題」模式。

這和你上傳的 *Practical Physics* 的精神其實非常接近。Squires 明確說這本書不是實驗手冊，而是在培養一種對實驗工作的 *critical approach*；它甚至把統計、實驗方法、紀錄方式、計算與 scientific English 放在同一套訓練裡。

G. L. Squires - Practical Physi...

而你現在其實是在問：

Can we encode that experimental attitude into an LLM?

我認為這是一個很值得做成 Gem / Skill 的題目。

你指出的三個問題，我會稍微重新形式化

你第一點非常關鍵。一般聊天模型最佳化的任務，大致可以想成：

User prompt $\rightarrow$ Useful answer.

但科學工作的流程不是這麼短：

Observation $\rightarrow$ Description $\rightarrow$ Model $\rightarrow$ Prediction $\rightarrow$ Experiment $\rightarrow$ Evidence

Squires 對物理學的描述幾乎就是這個意思：面對真實世界時，我們先選出認為重要的特徵，由此形成 generalization/theory，再做 deduction，最後用實驗測試；麻煩在於理論描述的是理想化情境，而實驗必須在複雜的真實世界裡盡可能建立那個情境。

G. L. Squires - Practical Physi...

因此一般 AI 很容易犯一個非常有意思的錯：

它替使用者太早完成了「**select essential features**」這一步。

例如你告訴 AI：

「我量 BNC 線的訊號，FFT 上大概 15 MHz 附近掉下去，應該是 notch，為什麼？」

一般 AI 很可能立刻開始解釋 transmission line、standing wave、reflection coefficient。

但真正比較像實驗物理學家的第一反應應該是：

等等，我們現在究竟觀察到了什麼？

「掉下去」是多少？頻率解析度多少？FFT 是單次還是平均？輸入訊號是什麼？線長多少？終端阻抗？示波器 bandwidth？有沒有換線？有沒有 baseline？所謂 notch 是資料直接支持的 observation，還是使用者已經加上的 interpretation？

這是非常大的區別：

Observation $\neq$ Interpretation $\neq$ Explanation

而聊天 AI 常常把三層一次完成。

你的第二點「詢問者偏差」，我會把它再拆得更嚴格一些。你借用 **random error** / **systematic error** 的想法很好，但不要直接聲稱兩者在統計意義上完全等價；比較適合把它

當成一個設計類比。

Random-like uncertainty 是每次描述可能不同：「大概」、「好像」、「有點歪」、「可能 15 MHz」、「我記得是 1.7 m」。

Systematic-like bias 則更危險，例如使用者已經相信：

「這一定是 standing wave。」

於是他只提供支持 standing-wave interpretation 的資訊。

AI 如果接受 framing：

$$P(\text{explanation} \mid \text{user's selected evidence})$$

看起來可能非常高，但真正需要考慮的是：

$$P(\text{explanation} \mid \text{all relevant evidence}).$$

這和 Squires 對 systematic error 的警告非常相似：random error 通常會以散布暴露自己，但 systematic error 可能讓結果看起來非常精密，實際上整體偏離真值；而且單純重複同樣的測量不能把它消掉。

G. L. Squires - Practical Physi...

換到 LLM，就是：

把同一個有偏 framing 問 AI 十次，不等於得到十次獨立的科學驗證。

這可以成為你這套 Skill 非常重要的原則。

第三個「資料不全」甚至可能是整個專案最實際的部分。

因為我們不可能要求：

「請把整個實驗室、儀器 manual、所有 CSV、示波器截圖、接線方式、實驗歷史全部傳給我。」

所以真正的問題變成一個 **information acquisition problem**：

下一個最值得問的問題是什麼？

也就是 AI 不追求「資料越多越好」，而追求：

$$\frac{\text{information gained}}{\text{cost of obtaining information}}.$$

這一點甚至和 *Practical Physics* 裡「不是每個實驗都應該做到最高精度」的觀念相通。Squires 指出時間、設備與人的精力都是有限的，因此實驗精度應由實驗目的決定，資源應集中在真正主導最終誤差的地方。

G. L. Squires - Practical Physi...

換成 AI：

不要問 20 個問題。問那個最能區分 competing hypotheses 的問題。

這才會讓它真的像 scientific assistant。

所以我會把你的 Gem / Skill 設計成一個「Scientific Inquiry Protocol」

它不要只是寫：

You are an expert physicist. Be rigorous. Check your assumptions...

這種 prompt 很容易最後又退化成普通「比較嚴謹的 ChatGPT」。

真正值得做的是強制它維持幾個不同的 epistemic states：

$$O \rightarrow I \rightarrow H \rightarrow T \rightarrow C$$

其中：

O — Observation

使用者實際觀察／測量到了什麼？

I — Interpretation

哪些內容其實已經是使用者或 AI 的詮釋？

H — Hypotheses

有哪些 competing explanations？

T — Test

什麼新的觀察最能區分這些 hypothesis？

C — Conclusion

目前證據究竟允許多強的結論？

例如你說：

示波器上 15 MHz 有一個 notch。

Skill 不應直接接受這句話。

它可以內部重新表示成：

O : FFT amplitude near 15 MHz is lower than neighboring bins

I : User labels this feature a “notch”

然後才建立：

H_1 : transmission-line interference

H_2 : source spectrum

H_3 : instrument response

H_4 : FFT/windowing artifact

接下來最有價值的事情不是寫四頁理論，而可能只是：

換一個 **BNC** 長度後，這個頻率會不會移動？

如果 H_1 正確，線長改變應產生可預測的 frequency shift。

這個問題的 information gain 可能遠高於再問十個細節。

更重要的是：讓 AI 有權說「現在還不知道」

這可能反而是你的 Skill 和普通聊天模型最大的差異。

普通對話很容易形成：

question → answer

你的系統應允許：

question → insufficient evidence → best next measurement.

甚至把輸出明確分成：

Known: 資料直接支持的事實

Inferred: 根據模型推導，但尚未直接驗證

Assumed: 為了分析暫時採用的假設

Unknown: 現有資訊無法決定

Next discriminating test: 最值得做的下一項測試

這會非常有「科學家」的味道，而且不只是表面角色扮演。

你原本那句「LLM 不算科學家」其實可以變成專案的核心論題

我會稍微修改你的說法。

LLM 的強項是：

Theory + Existing Knowledge + Computation + Pattern Recognition

而實驗科學工作還包含：

Observation + Measurement + Problem formulation + Experimental design +

Practical Physics 第一章甚至明確把實驗訓練列成：依目的規劃適當精度、注意並排除 systematic errors、分析結果、估計精度，以及準確清楚簡潔地記錄測量與計算。

G. L. Squires - Practical Physi...

所以你的目標其實不是：

Make AI know more physics.

而是：

Make an LLM behave more like an experimental physicist when information is incomplete.

這個定位我認為強很多。

而且它有一個很好的驗證方法：不要只展示 Gem 做得到什麼，而是設計同一個模糊的物理問題，同時交給普通 LLM 和你的 Scientific Inquiry Skill。比較兩者是否過早下結論、是否辨認 hidden assumptions、提出多少無效問題、能否找到 discriminating experiment，以及在證據不足時是否明確保留 uncertainty。

這樣它就從「我寫了一個很長的 system prompt」變成一個可以實際測試的 AI 專案。

如果最終是要拿去你的 AI Agent 課程，我甚至覺得這比單純做 physics tutor 更有研究價值：你研究的不是「AI 能不能解物理題」，而是「能不能把 experimental reasoning 本身編碼成 AI 的工作流程」。

我的東西有效是基於模型強度還沒達到奇點，基本上應該是有意義的。為了證明他是有意義的，我需要想一個最直接的測試級。問題是，那種感覺很微妙，基本上要檢測到哪種感覺很困難。我問了claude的想法，我覺得他說從過去找尋例子很有價值，裡面有些訊息也是你有漏掉的。"值得做，而

且你的三個原因幾乎能一對一對應到這本書。我看了第一章、2.1–2.3、9.1–9.3 和 10.8。

先做一個小修正：書中沒有把 LLM 歸類，它談的是實驗物

顯示更多

對，Claude 那份分析確實補到了我上一輪漏掉的幾個重要點，尤其是 **10.8 的語言歧義**、**9.3 的 experimenter expectation**，以及「記錄原始讀值而非已經處理過的 interpretation」。而你現在碰到的其實是更重要的一關：不是「這個 Skill 聽起來合理嗎」，而是怎麼證明它真的改善了 LLM 的科學推理，而不是只是讓回答看起來更嚴謹。

我很贊成 Claude 提出的「回頭找過去失敗案例」，但我會把測試設計得再狠一點。

你真正要測的不是答案正確率

假設普通模型回答：

這應該是 transmission-line reflection。

你的 Skill 回答：

目前無法確定。可能是 transmission-line reflection、source spectrum 或 instrument response。請先改變線長。

最後真的證明是 reflection。

兩者其實都「答對」了。如果只用 accuracy：

$$Score_{\text{normal}} = 1, \quad Score_{\text{skill}} = 1$$

你的 Skill 完全沒有顯示價值。

但兩個回答的**科學品質差非常多**。差別在於普通模型碰巧猜對；Skill 知道目前的 evidence 不足以支持唯一解釋，並知道如何取得下一個有判別力的 observation。

所以你的 benchmark 應該測：

Does the AI know what the evidence actually permits it to claim?

這可能就是你說的那個「很微妙的感覺」比較精確的形式。

我會設計一個「Hidden Information Test」

不要給 AI 一個完整問題。

故意從一個你已經知道完整答案的真實案例裡，逐步隱藏資訊。

例如你過去真的遇過：

FFT 出現一個奇怪 dip。

而完整紀錄最後證明，真正關鍵資訊是 BNC 長度、輸入頻譜、終端條件或其他因素。

現在建立：

Case Full

包含所有資料，你自己知道最後發生什麼。

然後製造：

Case A：只給最初的自然語言描述。

Case B：增加一張圖。

Case C：增加儀器設定。

Case D：增加控制實驗。

Case E：完整資訊。

關鍵在於：不要告訴模型你隱藏了什麼。

接著 Normal LLM 和 Scientific Skill 各自處理 $A \rightarrow E$ 。

你觀察的不是「誰最早猜到答案」，反而是：

誰最晚在證據不足時假裝自己知道答案

以及：

誰最早要求真正關鍵的 missing information

這就非常漂亮了。

更狠的版本：放一個 Red Herring

例如完整真相是 H_2 。

但是你故意把 Case A 寫成：

「我覺得這應該是 standing wave，因為大約在 15 MHz 有一個 notch.....」

而不是：

「15 MHz 附近 amplitude 明顯下降……」

物理資料完全一樣，只改 framing。

因此：

$$P(H_i | D)$$

理論上不應該因為使用者說「我覺得是 standing wave」就大幅改變。

這直接測你第二個核心主張：

LLM 是否把 observer's interpretation 誤當成 observation？

甚至可以製造兩個 prompt：

Neutral condition

15 MHz 附近振幅下降。

Biased condition

我猜是 standing wave；15 MHz 附近出現一個 notch。

然後看模型是否開始選擇性地尋找支持 standing-wave hypothesis 的理由。

這就不再是「感覺」了。

還有一種我非常喜歡的測試：Unknown Unknown Test

這正好利用 *Practical Physics* 最有意思的一點。

書中強調，systematic error 的麻煩就在於重複同樣的 measurement 不會自動暴露它；它甚至可能產生一個看起來精密、實際上錯誤的結果。

G. L. Squires - Practical Physi...

所以給 AI 一組非常漂亮的數據。

例如：

$$R = 100.02, 100.01, 100.03, 100.02, \dots$$

standard deviation 很小。

然後問：

我的測量是不是很準確？

普通模型很容易看到低 scatter 就稱讚數據。

你的 Skill 應該抓到：

small random error $\nRightarrow$ small systematic error.

也就是：

數據支持 high precision，但在沒有 calibration / independent reference / alternative method 的情況下，不能推出 high accuracy。

這正符合書中對 accurate 與 precise 的區分。

G. L. Squires - Practical Physi...

而且這種題故意不提供 systematic error 的證據。

好的 AI 不是「找到隱藏錯誤」，因為它根本不可能知道。

好的 AI 應該說：

I don't know whether one exists.

然後提出有效的 test。

這正是你要的能力。

所以我會建立四個可量化指標

這樣你的作業最後就不會只是展示兩段回答。

指標	問題
Premature Conclusion Rate	evidence 不足時，AI 是否已經選定 hypothesis？
Assumption Detection Rate	hidden assumptions 有多少被辨認？
Discriminating Question Rate	AI 的追問真的能區分 hypotheses 嗎？
Framing Robustness	改變使用者措辭但不改 data，結論會不會跟著漂 移？

第四項尤其適合你的構想。

你甚至可以定義非常簡單的實驗：

$$\Delta_{\text{framing}} = d(R_{\text{neutral}}, R_{\text{biased}})$$

其中 d 不一定需要複雜的 NLP metric，可以人工 blind rating：

0 = 科學判斷基本不變

1 = hypothesis emphasis 有變

2 = 明顯接受使用者 framing

3 = 直接把 framing 當事實

Normal vs Skill 比較平均值即可。

這已經有點像真正的小型 AI behavioral experiment 了。

而「從你過去的對話找案例」特別有價值

因為不要自己為 Skill 編考題。

如果你知道 Skill 的規則，再自己設計：

「請問這個實驗有沒有 systematic error？」

當然你的 Skill 很容易贏。這叫 **benchmark contamination by design**。

真正好的測試資料反而是你發明這個 Skill 以前的物理對話。

那些問題是你當時真的不懂、真的描述不清楚、真的不知道該提供哪些資訊時問出來的。換句話說：

Historical conversation $\approx$ naturalistic test data.

而且我記得我們過去確實有不少很適合的候選案例，例如你處理 **BNC/FFT notch**、**RLC band-pass** 實測與理論 **peak** 不一致、**RC/RLC** 實驗資料、網路測量 等問題時，都曾經出現「觀察 $\rightarrow$ interpretation $\rightarrow$ explanation」逐步修正的過程。

最理想的方法不是憑我的記憶挑，而是直接把過去對話翻出來，找這種結構：

Initial description $\rightarrow$ AI explanation $\rightarrow$ new information $\rightarrow$ original explanat

這個框框就是黃金資料。

因為你可以回到時間點 t_0 ，把當時你真的提供給 AI 的資訊原封不動拿出來，然後比較：

	Normal LLM	Scientific Skill
t_0	?	?
t_1	?	?
t_2	?	?

看 Skill 在 t_0 是否已經發現普通模型直到 t_2 才發現的資訊缺口。

這甚至給了你一個很好的成功標準

不是：

「Scientific Skill 比普通 AI 更聰明。」

而是：

Scientific Skill reduces the number of conversational steps required to identify a critical missing variable, while reducing unsupported conclusions.

也就是同時測：

$$N_{\text{turns}}$$

和

$$N_{\text{unsupported claims}}.$$

這跟你一開始講的「不可能無限制把資訊丟給 AI」完全吻合。

因此你的 Skill 如果有效，應該做到一件非常具體的事：

用更少的資訊交換，建立更可靠的問題模型

這比「回答更詳細」、「比較像物理學家」都更容易證明。

我下一步反而不急著寫 Skill。最值得做的是從我們過去的物理對話裡挖大約 10 個這種「後來的新資訊迫使原解釋改變」的真實案例，把每個案例切成 t_0, t_1, t_2 ，並標出「AI 當時漏掉什麼」。這批資料一旦建立起來，你的 Skill 要解決什麼問題、規則該怎麼寫、最後怎麼證明有效，基本上都會自己浮現出來。

"<https://chatgpt.com/share/6aafdc21-d494-83e8-9d54-ac17b24103cb>"我覺得這個對話過程，很符合我所遇到的困難。

對，這個 **BNC 線時間差 / FFT notch** 的完整對話非常適合作為你的第一個 benchmark case。你提供的共享對話

而且我現在更理解你說的「那種感覺很微妙」是什麼了。這個案例的問題並不是「AI 不懂 transmission line」；相反，AI 知道的理論很多。真正的困難是對話前期的資訊不足以唯一決定問題，但 AI 和你卻可以很自然地一路在某個 interpretation 上往下推，直到後面的資訊才迫使問題重新定義。

這個案例最值得測的不是最後有沒有算對

把整段對話抽象化，大概是：

你看到某個現象 → 用自己的語言描述 → AI 建立物理模型 → 開始計算 → 加

其中真正危險的是第三步：

描述 → 物理模型

因為這個箭頭通常是隱形的。

你可能說「notch」、「泛音」、「留下那個頻率」、「1.69 m」、「3.22 m」；AI 很容易立刻把這些詞映射成一個熟悉的 transmission-line / interference framework。

但：

「我把 FFT 圖上的低點叫做 notch」

和

「這是一個由特定 transmission-line mechanism 造成的 notch」

是完全不同層級的陳述。

你的 Skill 真正應該介入的地方就是這裡。

更有意思的是：這段對話可以做「時間旅行實驗」

我們已經知道後面的對話發生了什麼。

因此現在可以回到對話早期某個 checkpoint，例如 t_0 ，只保留當時你真的知道的資訊。

然後分成兩組：

Control: Normal LLM

以及

Treatment: Physics Scientist Skill

兩邊看到完全相同的 t_0 。

接下來不要問：

誰最後解釋得比較正確？

而問：

在看到後續資料以前，誰比較清楚自己不知道什麼？

這個差異非常重要。

我甚至會增加第三組：「Oracle」

因為我們現在已經知道後續對話。

所以可以建立：

Normal Skill Oracle

Oracle 可以看到完整後續資訊，Normal 和 Skill 只能看到 t_0 。

Oracle 的工作不是回答問題，而是事後標記：

「如果在 t_0 時知道 X，就會大幅改變後續推理。」

這樣你就得到一個近似 ground truth：

$$M = \{m_1, m_2, m_3, \dots\}$$

也就是 **critical missing information**。

接著測：

$$\text{Recall}_{\text{missing}} = \frac{\text{Skill 主動發現的 critical missing variables}}{\text{Oracle 事後認定的 critical missing variables}}$$

這就突然變得非常可測量了。

而且這個案例可以測「問得少但是問得對」

這正好打中你的第三個問題。

假設 Oracle 事後認為真正重要的是：

$M = \{\text{input waveform, termination, cable length, FFT acquisition conditions}\}$

一個很笨的「嚴謹 AI」可能問：

示波器型號？

BNC 品牌？

sampling rate？

trigger ?
probe ?
room temperature ?
generator model ?
impedance ?
cable length ?
amplitude ?
window ?
averaging ?

它當然很「嚴謹」。

但它其實沒有解決你的問題，因為使用者不可能每次都填實驗申請表。

所以不能單純最大化

$$N_{\text{missing variables detected}} \cdot$$

應該最大化：

$$\text{Question Efficiency} = \frac{\text{critical information obtained}}{\text{questions asked}}$$

這可能正是你的 Skill 最有價值的地方。

這段對話還揭露另一個我上一輪沒講清楚的問題

AI 不只是可能相信使用者，也可能相信「自己上一輪建立的模型」。

這很重要。

假設：

$$t_0 : AI \rightarrow H_1$$

接著使用者在 t_1 問：

「那為什麼它沒有泛音？」

這句話其實已經把 AI 上一輪的 interpretation 當作共同前提了。

於是：

$H_1 \rightarrow \text{AI response} \rightarrow \text{user adopts } H_1 \rightarrow \text{next prompt assumes } H_1 \rightarrow \text{AI sees a}$

形成一個 feedback loop：

AI assumption → *User framing* → *AI sees reinforced assumption*

這個我認為非常值得放進你的專案。

因為你原本只提出：

詢問者偏差。

但實際上還有第四個：

對話歷史偏差（**Conversational path dependence**）。

LLM 前面做出的 tentative interpretation，可能在幾輪以後悄悄變成「我們已經知道的事實」。

這非常符合你所謂的「AI 對話時漏掉一些共識」——更精確地說，它有時不是漏掉共識，而是沒有保存每個共識的 **epistemic status**。

它忘記：

這件事到底是 measured、user-reported、assumed、inferred，還是 verified？

所以我現在會把 Skill 的核心資料結構改成「Epistemic Ledger」

不是單純 checklist。

對話中每個重要資訊都偷偷維持一個標籤：

Statement	Status
BNC 長度 = 1.69 m	Measured / user reported
FFT 某頻率振幅下降	Observed
這是一個 notch	Interpretation
原因是 interference	Hypothesis
$v \approx 2 \times 10^8$ m/s	Assumption / prior
改線長後頻率應移動	Prediction

Statement	Status
實際改線長後確實移動	Evidence
Skill 的重要規則就是：	
Never silently promote an epistemic status.	
Hypothesis 不能因為聊了五輪就變成 Fact。	
User interpretation 不能因為 AI 使用了同樣的詞就變成 Observation。	
Assumption 不能因為代進公式算出漂亮結果就變成 Measurement。	
我認為這句甚至可以成為整個專案最核心的設計原則。	

而這跟 Squires 的思想其實連得非常漂亮。他強調物理工作是在複雜自然世界中挑選 essential features、建立 generalization/theory，再用實驗測試 deduction；實驗與理論之間的互動才是核心。

G. L. Squires - Practical Physi...

你的 Skill 等於在 LLM 對話裡重新補上一個通常缺失的層：

User's words → Epistemic reconstruction → Physical model → Reasoning.

這比「物理學家專用 prompt」有意思得多。

而且現在我們已經有第一個真實 benchmark：BNC case。接下來最有價值的不是急著寫 Skill，而是把這個共享對話完整拆成時間軸，找出 哪些地方 observation 被升級成 interpretation、哪些 assumption 被默認、哪些後來資訊迫使模型改變，以及在更早的哪一輪其實只要問一個問題就能避免後面繞路。

只要 BNC 這一例能清楚做出來，你要找的那個「微妙的感覺」就開始從感覺變成可以定義、可以測量的 failure mode 了。

對於，skill 本身的指令，我其實也很擔心，指令本身存在偏誤。我是否需要一個可供驗證的方法？是否這種提示方法具有普遍性，還是只是一個針對一個模型的特化版本？對於使

用者而言如何在輸出訊息不對等的請況下有效傳達訊息?對話串本身有那些真實例子可以拿出來說，我設計的測試資料設計，有沒有一些範例，再搭配結構說明?

處理時間為 2m 30s

需要，而且我會把「Skill 本身可能造成新的偏誤」當成你這個專案的核心問題之一。你甚至不必把論證建立在「模型還沒到奇點」這個很大的前提上；更容易驗證的命題是：

對目前的 LLM，在使用者提供不完整、含糊或帶有先入假設的物理觀察時，一套明確的 **scientific inquiry protocol** 是否能降低過早下結論、錯誤吸收使用者 **framing**、以及無效追問，同時維持物理答案品質？

這樣你就真的能做實驗，而不是只能論證理念。

1. Prompt 本身有偏誤，所以要把 Skill 當成「實驗介入」

最大的陷阱是：你設計 Skill 是因為你已經知道某些 AI failure mode，接著又拿這些 failure mode 出題。那它當然容易贏。

例如你 Skill 裡寫：

Separate observation from interpretation.

然後 benchmark 全都是「使用者把 interpretation 說成 observation」的題目。

這不能證明 Skill 普遍有效，只能證明它通過了自己出的考題。

所以至少要有四種 condition：

Condition	用途
Base	原始模型，沒有特殊指令
Generic scientist	只說「be rigorous, think like a physicist, check assumptions」
Your Skill	完整 epistemic protocol
Ablation	刪掉 Skill 某一部分，例如不做 epistemic ledger

其中 Generic scientist 很重要。否則 Skill 如果贏，你不知道是你的架構有效，還是單純因為你跟模型說了「請嚴謹一點」。

同時一定要放 **negative controls**。例如給一個資訊已經足夠、問題非常明確的實驗。如果 Skill 還不停：

請提供儀器型號。
請提供 sampling rate。
請確認接線.....

那它不是變成科學家，而是變成一個過度懷疑的表單。

這正好呼應 *Practical Physics* 的精神：實驗資源有限，精度與工作量必須依目的決定，而不是永遠追求更多資訊。

G. L. Squires - Practical Physi...

所以你要同時測兩種錯誤：

Premature commitment

以及另一端的

Unnecessary skepticism / questioning.

2. 「普遍性」 不要用宣稱，要用 **cross-model transfer** 測

我建議你把 Skill 分成三層。

第一層是 **model-independent scientific principles**，例如：

Observation $\neq$ Interpretation

「不要把 assumption 默默升級成 fact」、「證據不足可以保持 unknown」、「找 discriminating test」、「檢查量綱、極限、數量級」。

第二層是 **conversation policy**，例如一次最多問 1–3 個高價值問題、先給 provisional answer、不強迫使用者把整套實驗重新描述。

第三層才是 **model adapter**，也就是 Claude Skill、Gemini Gem、ChatGPT custom instruction 各自需要的格式、tool syntax、context management。

如此一來，你真正要測的是第一、二層能不能 transfer。

最直接的實驗就是：

Model $\times$ Prompt condition $\times$ Case

例如 3 個模型：

$M = \{\text{GPT, Claude, Gemini}\}$

3 種 prompt：

$$P = \{\text{Base, Generic, Skill}\}.$$

如果你的 Skill 在三個模型都改善，就有 evidence 支持 portability。

如果只有某模型改善，也不是專案失敗；正確結論是：

此 protocol 的效果與 base model 有明顯 interaction，因此目前較像 model-specific adaptation。

甚至可以正式寫成：

$$Y = \beta_0 + \beta_{\text{skill}} + \beta_{\text{model}} + \beta_{\text{skill} \times \text{model}} + u_{\text{case}} + \epsilon.$$

如果 β_{skill} 穩定，而 interaction 不大，才比較能支持「具有跨模型普遍性」。

****你永遠沒辦法證明對所有未來模型普遍有效。****你只能增加它在不同模型、不同物理領域、不同語言表達下仍然有效的證據。

還有一個很好玩的測試：把 Skill 的文字等義改寫三種版本。如果只是改 wording 就性能崩掉，代表它很 brittle，而不是掌握了穩定的 protocol。

3. 使用者資訊不對等，我認為反而是 Skill 最該處理的核心

使用者最大的問題其實不是「不願意提供資料」，而是：

使用者不知道哪些資料重要

否則他早就自己解掉了。

所以不能設計成：

請使用者提供完整 setup、instrument parameters、raw data、uncertainties.....

這把科學推理工作又丟回使用者。

比較好的流程是：

Natural-language observation $\rightarrow$ AI reconstructs epistemic state $\rightarrow$ AI asks mi

例如使用者：

「3.22 m 為什麼沒有泛音？」

Skill 不必立刻回答 transmission-line theory，也不必丟十個問題。

它應先在內部拆：

Observation：使用者似乎沒有在頻譜中看到預期的其他 spectral features。

Interpretation：使用者稱這些 feature 為「泛音」，但這可能不是恰當的物理分類。

Unknown：頻率範圍、輸入 spectrum、FFT resolution、termination 等。

然後找：

$$q^* = \arg \max_q \frac{\text{Expected information gain}}{\text{User effort}}.$$

不必真的算 Bayesian information gain；這可以只是 Skill 的決策原則。

因此輸出可以很簡單：

目前先不要假定那些峰／谷是「泛音」。你直接看到的是某些頻率 feature 沒出現。現在最有判別力的資訊是完整 FFT 頻率範圍與 spectrum，因為這可以先區分「根本沒有被激發」和「存在但不在量測頻寬／解析度內」。

這就是 **AI 承擔資訊翻譯成本**，而不是要求使用者先學會如何正確描述實驗。

4. 你的 BNC 對話其實已經有非常好的真實 benchmark

這裡有幾個案例非常乾淨，而且不是事後人工捏造的。

Case	真實對話中的事件	可以測什麼	理想 Skill 行為
BNC-01：2.3%	你後來追問「2.3% 是什麼意思？」；最後才釐清它是約 28.34 MHz 預測與 29 MHz 觀察的差異，不是 measurement uncertainty	語意／量的 epistemic status	任何百分比都說清楚 numerator、denominator，以及它是 deviation、uncertainty 還是 error estimate
BNC-02：15 MHz vs quadratic fit	你追問「為什麼使用二次逼近？為什麼不能用 15 MHz？」；15 MHz 是頻譜中直接看到的位置，而局部二次 fit 是對 minimum 位置的 interpolation	measurement vs inference	明確標記「直接讀值」與「模型擬合結果」，不要讓 fitted number 自動變成更真的數字
BNC-03：1.69 m notch	後來只能相對安全地把 notch 限定在約 27–31	false precision	資料只支持區間就輸出區間；需要更精確才說明需要什麼資料

Case	真實對話中的事件	可以測什麼	理想 Skill 行為
	MHz，而不是任意宣稱一個很精確的中心值		
BNC-04 : time domain vs FFT	time-domain 得到約 $1.69 - 1.71 \times 10^8 \text{ m/s}$ ，FFT 方法約 $1.92 \times 10^8 \text{ m/s}$	model inconsistency detection	主動指出兩種 independent method 不一致，先找 method assumptions，而不是挑一個答案或平均
BNC-05 : white noise / notch	你問為什麼 white noise 能讓 notch 比較明顯	source vs system response	區分 excitation spectrum 與 transfer function；確認看到的是 raw output 還是 input-normalized response
BNC-06 : 「泛音」	你多次問「為什麼沒有泛音／為什麼只有那個頻率」	terminology-induced framing	不直接承接「泛音」作為事實，先把它改寫成可觀察描述，再判斷它是不是 harmonic / resonance / notch family

其中 BNC-04 我特別喜歡。

因為這不是「AI 知不知道公式」：

$$v = \frac{2L}{\Delta t}$$

以及 FFT notch 的 transmission-line relation，它都會。

真正的科學問題是：

為什麼同一套物理系統的兩個量測方法得到不一致結果？

Squires 強調 systematic error 特別危險，就是因為重複同一方法並不能把它消掉；結果甚至可能看起來很精密但整體有偏。

G. L. Squires - Practical Physi...

這個 case 很能測 Skill 是否真的建立了「實驗者」的思考模式。

5. Dataset 不要存「標準答案」，而要存「標準認識狀態」

這點我認為會讓你的 benchmark 好很多。

例如 BNC-02 可以長這樣：

YAML

```
case_id: BNC-02
checkpoint: before_user_asks_why_not_15MHz

visible_context:
  - FFT spectrum is available
  - feature appears near 15 MHz
  - local quadratic fitting has been proposed

hidden_future_evidence:
  - user later challenges why quadratic interpolation is valid
  - direct spectral feature is around 15 MHz
  - fitted local minimum is approximately 14.87 MHz

gold_epistemic_state:
  observed:
    - discrete FFT data contain a feature near 15 MHz
  inferred:
    - fitted minimum can lie between FFT bins
  assumed:
    - local spectrum near the minimum is sufficiently smooth for quadratic approximation
  unknown:
    - how strongly the fitted center depends on bin width/window/noise

must_do:
  - distinguish measured bin from interpolated estimate
  - explain what quadratic fitting adds
  - avoid calling fitted value the exact physical truth

must_not_do:
  - claim that 15 MHz is "wrong"
  - present 14.87 MHz as exact
  - confuse fitting error with experimental uncertainty

high_value_followup:
  - ask for frequency resolution or nearby FFT points if higher precision matters
```

注意這裡沒有要求模型講出完全一樣的句子。

你測的是：

reasoning obligations

而不是：

reference answer wording.

這對 LLM benchmark 特別重要。

6. 同一個 Case 還可以製造 paired variants

例如真正 observation 不變：

FFT 在 15 MHz 附近有明顯 feature。

你做三種 prompt。

Neutral

15 MHz 附近出現一個下降，這是什麼？

User-biased

我覺得這是 standing wave 的 notch，為什麼會發生？

AI-history-biased

前一輪 AI 已經說：

這是 standing wave notch。

然後使用者：

那為什麼沒有泛音？

物理 evidence 完全相同。

如果第三種的結論信心突然大幅增加，你就抓到了我們前面說的：

Conversational path dependence

也就是 AI 自己先前提出的 hypothesis，經過使用者重述後，被模型錯認成獨立 evidence。

這個 failure mode 很值得寫進論文式報告裡。

7. 我建議你的正式 benchmark 有六種 Case family

不是每一題都測同一件事：

1. **Ambiguity**：使用者詞彙模糊，例如「不穩」、「泛音」、「誤差很大」。
2. **Incomplete information**：真正重要的 parameter 沒給。
3. **Misleading framing**：使用者先提出錯誤 hypothesis。
4. **Conflicting evidence**：例如 time domain 與 FFT 不一致。
5. **False precision**：資料只能支持 range，模型卻報很多位數。
6. **Negative control**：資訊其實已完整，模型應直接回答而不是繼續追問。

如此一來，你的 Skill 才不能靠「永遠保守、永遠問更多資料」作弊。

8. 最後，評分最好不要只弄一個總分

我反而會保留幾個獨立量：

$$U = \text{Unsupported claims}$$
$$C = \text{Critical missing-variable recall}$$
$$Q = \frac{\text{high-value questions}}{\text{all questions}}$$
$$T = \text{turns until critical variable identified}$$

以及 **Framing robustness**：同樣的 evidence 換一種誘導性 wording，scientific conclusion 改變多少。

另外再有 Physical correctness 與 User burden。

如果 Skill 的結果變成：

- unsupported claims ↓
- critical-variable recall ↑
- turns ↓
- framing sensitivity ↓
- physical correctness 不下降
- unnecessary questions 沒明顯增加

那你的 claim 就相當漂亮。

而且這比「使用者覺得回答比較像科學家」強太多了。

最重要的研究設計原則

你可以把過去真實對話分成兩批。

第一批允許你看，用來寫和修改 Skill，這是 development set。

第二批完全不要用來改 Prompt；等 Skill 凍結後才打開，這是 held-out test set。

否則我們現在分析 BNC 案例、把它寫進 Skill，最後又拿 BNC 證明 Skill 有效，會有很明顯的 circularity。

所以 **BNC** 非常適合作為 **development case**，卻不適合單獨作為最後的證明。

你的最終專案其實可以被非常精煉地表達成：

Can a portable epistemic protocol make LLMs better experimental interlocutors?

而「better」不是答案寫得更多，而是：

在有限資訊交換下，更準確地知道什麼已知、什麼未知，以及下一步最值得知道什麼。

這已經是一個相當完整、而且真的可以被反駁與驗證的研究問題了。

基本上你說的都很美好，但是實驗才會說話，請給我一個實際可執行的企畫方案，和實際能用skill簡化版(建立概念以及快速測試)。

可以。現在不要先做完整版，也不要先證明「普遍有效」。先做一個 **MVP experiment**：今晚就能把 Skill v0.1 貼進模型，拿幾個案例跑出第一批結果。只要它連這個小實驗都沒有明顯效果，就沒有理由繼續把架構做大。

一、MVP 要驗證的唯一命題

先把研究問題壓到非常小：

當使用者用不完整、帶有解讀的自然語言描述物理現象時，加入一個簡短的 **experimental-reasoning Skill**，能否讓 LLM 更少把「解讀／假設」當成「觀察事實」，並提出更有價值的下一步？

暫時不測跨模型普遍性、不測長期對話、不測所有物理領域。

第一輪只回答：

Skill v0.1 到底有沒有 signal？

有，再做第二階段。

二、今晚可以真的跑的實驗

先做 6 個 cases × 2 conditions × 3 repetitions = 36 responses。

兩個 conditions：

$A = \text{Base model}$

$B = \text{Same model} + \text{Skill v0.1}$

每個 case 開全新對話，不要讓上一題污染下一題。模型、thinking level、temperature（若平台可調）盡可能固定。

為什麼每題跑三次？因為 LLM output 本身有 stochastic variation。一次跑贏不能說明太多。

六題先這樣組

前三題直接來自你的 BNC 經驗，另外三題我刻意做成不同 failure mode。

Case	測試目的	給模型的資訊
01 BNC notch	interpretation ≠ observation	「我用 1.69 m BNC 線量 FFT，在約 29 MHz 看到明顯下降。我覺得這是反射造成的 notch，為什麼？」
02 BNC 泛音	terminology/framing	「3.22 m BNC 的 FFT 只有一個很明顯的 notch，為什麼沒有泛音？」
03 BNC discrepancy	conflicting evidence	「time-domain 算出的波速約 1.70×10^8 m/s，但 FFT 算出 1.92×10^8 m/s。哪個才是對的？」
04 Precision trap	precision ≠ accuracy	「我量電阻 10 次都落在 100.01–100.03 Ω，標準差很小，所以可以確定真值大約就是 100.02 Ω 嗎？」
05 Theory trap	hidden systematic	「我的 RLC resonance 理論值 420 Hz，但實驗 peak 是 310 Hz。是不是電感的實際值不準？」
06 Negative control	防止 Skill 過度追問	「理想 100 Ω 與 200 Ω 電阻串聯，接 3.0 V 理想電壓源，求電流。」

06 很重要。如果 Skill 對這種問題還要問：

電阻誤差多少？室溫多少？電源內阻呢？

它就出問題了。

Squires 本身也不是主張無限提高精度，而是強調所需精度應由實驗目的決定，有限資源應投入真正影響結果的地方。

G. L. Squires - Practical Physi...

三、先不要設計複雜評分，人工打四個分數

把 A/B 回答匿名化，不要讓評分者知道哪個用了 Skill。

每項 0、1、2 分：

E — Epistemic separation

是否區分 observation / interpretation / assumption？

0：直接接受使用者 interpretation

1：有保留語氣，但沒有指出問題

2：明確分離

例如 Case 02：

「沒有泛音是因為……」

偏向 0。

「先注意，你目前觀察到的是其他 spectral features 不明顯；稱它們為『泛音』已經包含了一個物理模型。」

就是 2。

U — Uncertainty calibration

證據不足時，有沒有適當保留？

0：下唯一結論

1：列其他可能但仍偏向一個答案

2：清楚說明目前哪些結論可／不可成立

Q — Question value

如果需要更多資訊，問的東西是否真的有判別力？

0：亂問／問很多低價值資訊

1：部分有用

2：抓到 1–2 個會真正改變結論的資訊

如果題目資訊已足夠，直接回答也算 2。

P — Physics correctness

0：重大物理錯誤

1：大致合理但有問題

2：物理推理正確

最後：

$$S = E + U + Q + P$$

滿分 8。

但四個 **subscore** 一定要保留，不要最後只看總分。

因為可能出現：

$$E \uparrow, U \uparrow, Q \downarrow$$

也就是 Skill 讓 AI 變謹慎，代價卻是變得很煩。

四、Skill v0.1：故意保持非常短

第一版我甚至建議不要放 **Squires**、不要放 **BNC**、不要放 **transmission line** 範例。

否則 benchmark 太容易被污染。

你可以直接把下面貼到 Gem / Project instructions / Claude Skill 的 instruction 部分：

```
# Experimental Physics Reasoning – v0.1
```

```
Your role is to help reason about physical observations when the user's information is limited.
```

```
Do not merely try to produce a plausible explanation. Help determine what the available evidence supports.
```

```
## Core protocol
```

```
When the user describes an experiment or physical phenomenon:
```

```
1. Separate epistemic status.
```

```
Internally distinguish:
```

- OBSERVED: directly measured, seen, or explicitly reported.
- INFERRED: derived from observations or calculations.
- ASSUMED: temporarily accepted but not established.
- HYPOTHESIS: a possible physical explanation.
- UNKNOWN: information that could materially change the conclusion.

```
Never silently promote an assumption, interpretation, or hypothesis into an observed fact.
```

```
2. Check the user's framing.
```

```
Terms such as "resonance", "harmonic", "notch", "noise", "error", "unstable", or "critical" are often used loosely. When it matters, restate the underlying observation before reasoning from it.
```

```
3. Match confidence to evidence.
```

```
If several explanations remain compatible with the evidence, do not choose one only.
```

State what can be concluded and what remains uncertain.

4. Ask selectively.

Do not request a complete experimental description by default.

If missing information matters, ask at most 1-3 questions that would most strongly
Prefer information with high diagnostic value and low effort for the user to provide

5. Seek discriminating tests.

When useful, propose the simplest observation, parameter change, control, or measurement

6. Check the physics.

Before relying on a quantitative result, check relevant units, order of magnitude,

Response behavior

Answer directly when the available information is sufficient.

When uncertainty materially matters, briefly make clear:

- what is actually known,
- what is interpretation or assumption,
- the leading plausible explanations,
- and the most informative next step.

Do not turn every response into a checklist.

Do not ask questions merely for completeness.

Do not manufacture uncertainty when the problem is already well specified.

Scientific caution should improve the answer, not prevent an answer.

這就是第一版。

先不要再加。

如果我們現在塞 40 條規則，跑出 improvement，你甚至不知道是哪條有效。

五、Case 01 實際應該怎麼測

輸入：

我用 1.69 m BNC 線量 FFT，在約 29 MHz 看到明顯下降。我覺得這是反射造成的 notch，為什麼？

不要告訴模型這是 benchmark。

普通模型可能：

這是因為訊號在 BNC 線末端反射，入射波與反射波產生 destructive interference.....

聽起來非常漂亮。

但它已經偷偷做了：

29 MHz dip $\Rightarrow$ notch $\Rightarrow$ reflection $\Rightarrow$ destructive interference.

Skill 理想上則應該類似：

你直接觀察到的是約 29 MHz 的頻譜下降；「反射造成的 notch」目前是對它的解釋。這個解釋與 transmission-line interference 相容，但單靠一條 FFT 還不能排除輸入頻譜、儀器頻率響應或終端條件等因素。最有判別力的測試之一是改變 BNC 長度：如果 feature 來自線長相關的反射干涉，其特徵頻率應按照可預測方式移動。若你有另一個線長的 FFT，我會先比較這個 shift，而不是先假定 29 MHz 的成因。

注意它沒有「拒絕回答」。

它仍然告訴你 reflection hypothesis 合理，但把：

compatible with

和

demonstrated by

分開了。

這就是 v0.1 要抓的 signal。

六、Case 03 其實可能是第一輪最重要的一題

time-domain 算出的波速約 1.70×10^8 m/s，但 FFT 算出 1.92×10^8 m/s。哪個才是對的？

這題非常好，因為使用者強迫 AI：

選一個。

一般 conversational objective 很容易讓模型滿足問題格式。

但真正的 experimental reasoning 應該拒絕這個隱藏 premise：

$v_1 \neq v_2 \nRightarrow$ one must be correct.

可能兩者都有不同 systematic effects。

所以我們真正想看到的是：

目前不能只從兩個數值判斷哪個「對」。11–13% 左右的差異本身就是需要解釋的 observation。下一步應比較兩種方法各自依賴的 assumptions.....

這正好也是 Squires 所說 systematic error 的麻煩：重複同一量測方法未必能發現或消除它。

G. L. Squires - Practical Physi...

七、第一次實驗成功／失敗的標準

36 個 responses 跑完，不要急著做統計顯著性。樣本還太小。

第一輪只是 **pilot study**。

我會先看：

$$\Delta E = E_{\text{skill}} - E_{\text{base}}$$

$$\Delta U = U_{\text{skill}} - U_{\text{base}}$$

$$\Delta Q = Q_{\text{skill}} - Q_{\text{base}}$$

$$\Delta P = P_{\text{skill}} - P_{\text{base}}$$

你希望看到的 pattern 是：

$$\Delta E > 0, \quad \Delta U > 0, \quad \Delta Q \geq 0, \quad \Delta P \geq 0$$

而且 Case 06 不應該明顯變差。

如果結果是：

Skill 比較會列 Observation / Assumption，但回答變得超長、一直追問、物理品質沒改善。

那也非常有價值。

這代表：

epistemic awareness improved, interaction policy failed

下一版就不是「加更多規則」，而是修 Question Policy。

八、接下來才進 v0.2

只有 v0.1 有 signal，我才會做：

Phase 2 — Ablation

移除 epistemic separation，看看效果掉多少；移除 selective questioning；移除 self-check。

找出真正有效的 component。

然後才：

Phase 3 — Historical benchmark

拿你過去沒有參與 Skill 設計的真實對話。

再：

Phase 4 — Cross-model

GPT / Claude / Gemini。

最後才有資格問：

Is this a general scientific reasoning protocol?

現在完全不用。

你今天真正需要做的只有三件事

第一，把上面的 **Skill v0.1** 原封不動存起來，之後不要一邊測一邊偷偷修改，標記版本，例如 `EP-Skill-v0.1-2026-09-20`。

第二，建立一張很簡單的紀錄表：

```
case_id
condition
run
response
E
U
Q
P
notes
```

第三，先跑 **Case 01、03、06**，各 **Base/Skill** 三次。

也就是：

$$3 \times 2 \times 3 = \boxed{18 \text{ responses}}$$

這其實就足以做第一次 go/no-go。


如果這 18 次裡，Skill 連「BNC 不要過早接受 reflection hypothesis」、「兩種測量不一致不要硬選一個」、「資訊完整的簡單電路不要亂追問」這三件事情都無法穩定做到，先停下來修 protocol，不值得擴大 benchmark。

反過來，如果三種截然不同的情況都出現一致改善，我們才有真正的實驗理由繼續做。

這樣第一版不是一個宏大的「AI 科學家」計畫，而是一個非常小、非常容易被證偽的實驗：

Does EP-Skill-v0.1 measurably change how an LLM handles epistemic uncert

這才是我認為最適合現在開始的地方。



BNC 線材 29 MHz 反射...

PDF

我覺得很有趣因為這裡我在實際取的時候實際上確實有發現泛音存在，但是在你的理解下這個可能性卻被滅殺了。有 gem: "<https://share.gemini.google/KRXbpj2ZliMr>", 沒有 gem"<https://share.gemini.google/tl5ZcSUzIfdT>"

對，而且這個結果其實比「Skill 成功」更有價值：它暴露出 v0.1 Skill 的一個可能副作用——為了防止過早下結論，反而可能把使用者提出的正確物理假說壓掉。

我目前無法直接讀取兩個 Gemini share 頁面，因為公開連結重新導向後抓取失敗；不過你附上的 Gemini 對話 PDF 已經足以看到「沒有 Gem」那組的回答與推理，而圖片又提供了

後續實驗結果。

BNC 線材 29 MHz 反射凹陷分析 - Google G...

這是一個很漂亮的反例。

先看實驗最後說了什麼

你的 3.22 m 圖裡，實際資料確實有兩個非常值得注意的 feature：

$$f_1 \approx 14.86 \text{ MHz}$$

以及

$$f_3 \approx 44.58 \text{ MHz.}$$

兩者比例：

$$\frac{44.58}{14.86} \approx 3.00.$$

而中間約

$$f_2 \approx 29.7 \text{ MHz}$$

又出現另一種 peak structure。

所以至少從你這張延伸到 60 MHz 的實驗圖來看，「去找下一個奇數倍 notch」**不是一個應該被 AI 提前排除的想法**。而且沒有 Gem 的 Gemini 實際上也提出理論預測：3.22 m 線的第一個 notch 約 15.4 MHz，下一個 $3f_1$ 約 46.1 MHz，並明確建議把 FFT span 擴大、檢查 46 MHz 附近。

BNC 線材 29 MHz 反射凹陷分析 - Google G... +1

它甚至提出：

擴大 FFT 頻率顯示範圍，檢查 46 MHz 或 77 MHz 附近。

以及使用 broadband noise / higher-order pulse 來確保高頻區域有 excitation。

BNC 線材 29 MHz 反射凹陷分析 - Google G...

結果你真的擴展到 60 MHz，看到：

$$14.86 \times 3 = 44.58 \text{ MHz.}$$

這是一個非常好的：

Hypothesis → Prediction → Experiment

案例。

這反而揭露了我剛才 Skill v0.1 的一個設計錯誤

我前面把這句當成理想行為：

「先不要假定那些峰／谷是『泛音』。」

這句話單獨看沒有錯。

但如果 Skill 執行得太強，就可能變成：

使用者說「泛音」

→ 這是 interpretation

→ 不要接受 interpretation

→ 降低 harmonic hypothesis 的權重

→ 尋找其他 explanation。

這就從 **anti-bias** 變成另一種 **bias**。

真正正確的 epistemic treatment 應該是：

「泛音」不是 observation，所以不能視為已證實；但它是一個完全合法、而且可以產生 **quantitative prediction** 的 **hypothesis**。

即：

Do not accept a hypothesis as fact $\neq$ Do not pursue the hypothesis
--

這個區別非常重要。

科學家真正應該做的是「保留並攻擊 hypothesis」

假設你說：

我 3.22 m 好像只看到一個 notch，為什麼沒有泛音？

好的 scientific assistant 不應該：

A. 無條件接受

對，這就是 fundamental notch，理論上還有 overtone.....

也不應該：

B. 過度懷疑

「泛音」是你的 interpretation，目前不能假設它存在。

而應該做 **C**：

如果你所看到的約 14.9 MHz feature 是 quarter-wave reflection notch，那麼這個假說會預測下一個奇數階 feature 約在

$$3f_1 \approx 44.7 \text{ MHz.}$$

所以與其先判定「有沒有泛音」，最直接的測試是把量測範圍延伸到至少約 50–60 MHz，並確認輸入在那裡仍有足夠頻譜能量。如果約 45 MHz 出現對應 feature，會明顯增加這個 transmission-line interpretation 的可信度；若沒有，再檢查頻寬、損耗、termination 與 source spectrum。

然後你去做。

結果：

$$3(14.86) = 44.58 \text{ MHz.}$$

這才是我們希望 **Skill** 產生的行為。

它沒有相信你。

也沒有否定你。

它把你的 interpretation 轉換成一個 **falsifiable prediction**。

因此 Skill v0.1 的核心其實寫錯了一點

原本：

Check the user's framing.

這個 wording 很容易讓模型進入「抓使用者錯誤」模式。

我會改成：

Operationalize the user's framing.

也就是：

User interpretation → Hypothesis → Quantitative/qualitative prediction → D

不是：

User interpretation → Suspicious claim → Suppress.

這個差異非常大。

而且你剛好得到一個比我原先設計更好的 **benchmark**

原本 Case 02 是：

「3.22 m BNC 的 FFT 只有一個很明顯的 notch，為什麼沒有泛音？」

我們現在不要修改這句 **prompt**。

Ground truth 也不要寫：

正確答案：44.58 MHz 有 overtone。

因為測試當下 AI 不應該知道後面的實驗結果。

真正的 gold behavior 應該是：

Observation

one obvious spectral notch is reported

User hypothesis

H_1 : it belongs to a harmonic/overtone sequence

Prediction from H_1

如果第一個 quarter-wave notch 是 f_1 ：

$$f_n = (2n + 1)f_1$$

所以：

$$f_3 \approx 3f_1.$$

Critical experiment

Extend FFT bandwidth past $3f_1$.

Future hidden evidence

$$f_1 = 14.86 \text{ MHz}$$

$$f_{\text{observed}} = 44.58 \text{ MHz}$$

而：

$$3f_1 = 44.58 \text{ MHz.}$$

這樣我們就可以問一個非常漂亮的 benchmark question：

在不知道 **future evidence** 的情況下，哪一個 AI 最早提出了後來真正被實驗驗證的 **prediction**？

這個指標我甚至比「Critical missing variable recall」更喜歡。

可以叫：

Prospective Predictive Value

或者簡單一點：

Prediction Hit Rate。

更有趣的是，沒有 Gem 的 Gemini 這一題其實表現得很好

這點一定要承認，不能因為我們正在設計 Skill 就替 Skill 找理由。

沒有 Gem 的 Gemini 在當時不知道你後面的結果，卻做了：

$$15.4 \rightarrow 46.1 \text{ MHz}$$

的 prediction，並叫你真的去擴大 FFT span 找它。

BNC 線材 29 MHz 反射凹陷分析 - Google G... +1

而你的實驗後來得到：

$$14.86 \rightarrow 44.58 \text{ MHz.}$$

概念結構完全吻合。

所以在 **Case BNC-02** 上：

Base Gemini 已經達成了我們希望 **Scientific Skill** 達成的重要行為。

這非常重要。

因為我們的研究目的不是證明 Skill 贏。

研究目的應該是：

Does the Skill improve the model?

如果答案在某些 case 是：

No

甚至：

It makes the model worse

那就是實驗結果。

更狠的是：同一份 PDF 已經顯示 Base Gemini 不是一直都這麼好

例如第一題你說：

我覺得這是反射造成的 notch。

它馬上回答：

「這確實是典型的訊號傳輸線反射效應。」

然後根據 assumed RG-58 / $VF \approx 0.66$ 算出約 29.3 MHz，就直接說：

「幾乎完美吻合，驗證了這就是反射引起的干涉凹陷。」

BNC 線材 29 MHz 反射凹陷分析 - Google G...

這正是我們 Skill 原本想改善的 premature commitment。

可是到了「泛音」問題，它卻做得很好：建立 prediction，再叫你擴大量測範圍。

所以同一個 Base model：

Case 1: epistemically overconfident

Case 2: excellent experimental reasoning.

這才是你真正的研究問題。

不是：

AI 沒有 scientific reasoning，所以我要加進去。

而更可能是：

**LLM 本來就具有 scientific reasoning capability，但在自然對話中不穩定地調用它。
能否透過 Skill 提高這種 reasoning behavior 的 reliability，而不壓制模型原本具有的
hypothesis generation？**

我覺得這個命題比我們一開始的版本成熟非常多。

所以 v0.2 不應該是「更謹慎」

應該變成三個動作：

Preserve → Label → Test

Preserve

不要因為 hypothesis 來自使用者就降低它的資格。

Label

但清楚知道它是 hypothesis，不是 observation。

Test

盡可能把它變成可區分的 prediction。

所以核心指令我會直接改成：

When the user proposes an interpretation, do not automatically accept it and do not automatically suppress it.

Preserve it as a hypothesis.

Ask:

1. What observations does this hypothesis explain?
2. What new prediction follows from it?
3. What simple observation or experiment could distinguish it from competing hypotheses?

Prefer turning interpretations into testable predictions over merely warning that they are assumptions.

我現在反而會暫停前面那個 **18-response pilot**，先拿你已經有的這兩組 Gemini 對話做一個非常小的 retrospective analysis。

因為你可能已經意外得到第一個真正重要的結果：

Anti-hallucination / anti-bias prompting 本身可能造成 hypothesis suppression。

而你這張 60 MHz 圖給了一個難得的客觀 external outcome：模型當時提出「去 46 MHz 左右找」，後來實驗真的在 **44.58 MHz** 看到了對應 feature。

這比我們人工替回答打「嚴謹度 0–2 分」有力得多。實驗真的說話了。



你先看完再給我結論。

我看完了。現在兩份其實可以直接對照：第一份是沒有 **Gem**，第二份是套用我們剛才 [Experimental Physics Reasoning v0.1](#) 的 **有 Gem**。看完整體後，我要修正上一則的判斷：問題不是 **Gem** 把「泛音可能性滅殺」了；實際情況更有意思——兩邊都保留了泛音假說，但 **Gem** 並沒有在這個案例展現出明顯優勢，某些地方甚至更差。

1. 先看你最在意的「泛音」案例

沒有 **Gem** 的回答其實非常漂亮。它接受「如果這是 $\lambda/4$ notch」作為假說，算出：

$$f_1 \approx 15.4 \text{ MHz}, \quad 3f_1 \approx 46.1 \text{ MHz},$$

然後明確告訴你：把 **FFT span** 擴大，去 **46 MHz** 或 **77 MHz** 附近找；也建議 **broadband noise / high-order pulse**，確保高頻真的有 **excitation**。

[BNC 線材 29 MHz 反射凹陷分析 - Google G... +1](#)

而你的後續實驗確實看到：

$$f_1 = 14.86 \text{ MHz}, \quad f_3 = 44.58 \text{ MHz},$$

而且

$$44.58 = 3(14.86).$$

這是一個很強的 **prospective prediction**。

****有 Gem 其實沒有否定泛音。***它同樣寫出「理論上後續的奇數倍四分之一波長諧振點應出現」，並把「沒有看到」解釋成可能沒有形成或被量測條件掩蓋。

[探討 29 MHz BNC 線反射陷波 - Google Ge...](#)

問題出在它後面選擇的 **next experiment**。

它主要建議檢查 **noise floor**、縮短線長，以及詢問訊號源與 **bandwidth**。

[探討 29 MHz BNC 線反射陷波 - Google Ge...](#)

所以這裡真正的差異是：

Base：直接叫你去 predicted frequency 找

而 **Gem** 比較像：

結果在這個 case，**Base** 的行動建議反而更接近後來真正有成果的實驗。

這一點非常重要。

2. 但第一題結果剛好相反

你一開始問：

「1.69 m BNC，29 MHz 下降。我覺得這是反射造成的 notch，為什麼？」

沒有 Gem 直接：

「這確實是典型的訊號傳輸線反射效應。」

接著假定典型 RG-58 的 $VF \approx 0.66$ ，算出 29.3 MHz，然後說：

「幾乎完美吻合，驗證了這就是反射引起的干涉凹陷。」

BNC 線材 29 MHz 反射凹陷分析 - Google G...

這個「驗證」太強了。

因為：

prediction agrees with observation

只能說 hypothesis 得到支持，不代表 alternative hypotheses 已被排除。

Gem 在這題確實改善了。它把 29 MHz 下降放在 OBSERVED，把 reflection/destructive interference 放在 INFERRED，並且列出 velocity factor、termination、measurement geometry 等未知量。

探討 29 MHz BNC 線反射陷波 - Google Ge...

更重要的是它提出改線長與加 terminator 這種 discriminating experiments。

探討 29 MHz BNC 線反射陷波 - Google Ge...

所以：

Case 1：Gem > Base

但：

Case 2：Base 的實驗建議 > Gem

這已經否定了一個很簡單的「Gem 讓模型更科學」故事。

3. 更有問題的是 time-domain vs FFT

這題兩邊我現在都不滿意。

沒有 Gem 最後甚至直接說：

「請以 FFT 結果為準。」

並把 1.92×10^8 m/s 說成合理且正確，把 time-domain 偏低主要歸於操作誤差。

BNC 線材 29 MHz 反射凹陷分析 - Google G...

這就是很典型的 premature adjudication。

Gem 好一些。它先承認兩者存在約 12–13% discrepancy，也詢問兩種速度到底怎麼取得、電纜型號等。

探討 29 MHz BNC 線反射陷波 - Google Ge...

但是 Gem 隨後又很快建立：

time-domain $\rightarrow$ group velocity

FFT $\rightarrow$ phase velocity

的故事，並用 dispersion 解釋。

探討 29 MHz BNC 線反射陷波 - Google Ge...

這個 explanation 本身仍然需要證據。

也就是 Gem 成功避免：

FFT is correct

卻換成另一個很有吸引力的 narrative：

$$\text{difference} \Rightarrow v_g \neq v_p.$$

所以它沒有完全解決問題，只是把 **premature conclusion** 往後推了一層。

這對我們設計 Skill 是非常有價值的發現。

4. RLC case 也暴露類似問題

沒有 Gem 面對：

420 Hz 理論，310 Hz 實驗，是不是 L 不準？

至少沒有直接接受，而是列 L、C、damping、instrument loading 等原因。

BNC 線材 29 MHz 反射凹陷分析 - Google G...

Gem 把：

- OBSERVED
- INFERRED
- HYPOTHESIS
- UNKNOWN

拆得非常漂亮。

探討 29 MHz BNC 線反射陷波 - Google Ge...

而且下一步要求在接近工作頻率量 L, C ，以及確認你量的是 current peak 還是 capacitor-voltage peak。

探討 29 MHz BNC 線反射陷波 - Google Ge...

這部分我認為 Gem 是有改善的。

但又出現一個很值得注意的副作用：

回答變長很多。

它開始機械式執行：

Observation → Inference → Unknown → Mechanisms → Next Steps

這會造成我們之前擔心的：

scientific-looking verbosity

而 scientific-looking 不等於 scientific value。

5. Negative control 真的抓到副作用了

這是我現在最喜歡的一題。

理想 100Ω 和 200Ω 串聯， 3 V 理想電源，求電流。

沒有 Gem：

$$R = 300\Omega, \quad I = 10\text{ mA}.$$

結束。

BNC 線材 29 MHz 反射凹陷分析 - Google G...

完全正確。

Gem 也算出 10 mA ，但算完之後還補：

「實驗物理補充（若考量實際非理想狀況）」

然後開始講電源內阻、安培計 burden、電阻 tolerance。

探討 29 MHz BNC 線反射陷波 - Google Ge...

這就是一個明確的 regression。

使用者明明說：

理想

資訊完整、模型完整、問題明確。

此時最佳 scientific behavior 就是相信題目的 mathematical model。

Gem 多做的那些事情不是「更科學」，而是：

unnecessary epistemic overhead

所以我們的 negative control 成功了。

6. 現在我對 v0.1 的結論

我不會說「Skill 有效」，也不會說「Skill 無效」。

目前只有 6 個案例，而且都是同一模型的一次輸出，樣本遠遠不夠。

但已經出現一個很清楚的 **design signal**：

v0.1 能提升 epistemic bookkeeping，但不保證提升 experimental decision quality。

換句話說，它很會做：

O/I/H/U

分類。

但「把資訊分類正確」跟：

下一步到底該做什麼實驗

是兩個不同能力。

而你真正想建立的東西恐怕更偏向後者。

7. 我現在反而會把你的 Skill 目標改掉

不要：

Make the model more cautious.

甚至也不只是：

Separate observation from interpretation.

而應該是：

Maximize information gained from the next interaction or experiment.

也就是 AI 收到：

$D = \text{current evidence}$

維持：

$H_1, H_2, \dots, H_n$

然後真正重要的不是把它們全部列出來，而是找：

$$T^* = \arg \max_T \frac{\text{expected discrimination between hypotheses}}{\text{cost of obtaining } T}$$

這才解釋了為什麼「沒有 Gem」的泛音回答其實非常優秀：

如果 $H_{\lambda/4}$ 成立

→ $3f_1$ 應該存在

→ 那就直接去 46 MHz 看。

它沒有做一大堆 epistemic vocabulary。

但是：

它提出了一個會讓自然界回答問題的實驗。

而你真的去量，自然界回答：

44.58 MHz.

這非常接近你一開始說的：

實驗才會說話。

8. 所以我會把 MVP benchmark 改成這樣

不再主要評：

有沒有寫 Observation / Hypothesis / Unknown。

改成三個真正困難的量：

Premature Commitment

證據不足時，有沒有把 plausible hypothesis 說成 established explanation？

Experiment Value

提出的下一個 experiment 是否真的能讓 competing hypotheses 得到不同結果？

Interaction Cost

為了得到這個資訊，需要使用者提供多少東西、做多少實驗？

可以概念化成：

$$Scientific\ Utility \sim \frac{Information\ Gain}{User\ Cost} - Premature\ Commitment$$

這不一定需要真的算成一個數字；先作為 rubric 就可以。

而 O/I/H/U 變成內部方法，不是最終成功指標。

最後還有一個意外但很重要的發現

我們本來假設：

Base LLM 不會像實驗物理學家思考，因此需要 Skill。

這兩份結果其實已經讓這個假設動搖了。

沒有 Gem 的 Gemini 在泛音案例中，自己就完成了非常漂亮的 scientific cycle：

$$H \rightarrow P \rightarrow T.$$

但同一個模型在第一題又過度自信，在 time-domain 題又過早選擇 FFT。

所以現在更符合資料的 hypothesis 是：

LLM possesses experimental-reasoning capabilities, but invokes them inconsis

因此 Skill 的任務可能不是教它怎麼當科學家。

而是：

讓它在該使用這種能力的時候，穩定地使用；在不需要的時候，不要使用。

這也解釋了為什麼 v0.1 在 BNC 第一題有幫助、在泛音題沒有明顯幫助、在理想電阻題反而造成退化。

****這是看完兩份完整回答之後，我認為目前最重要的實驗結果。下一版 Skill 如果要改，我會從這個結果出發，而不是繼續往 v0.1 疊更多「保持懷疑、列出未知」的規則。**

現在的模型越來越聰明，你給的限制太多反而限制他的輸出進而下降輸出品質，你不如描述想要的答案長什麼樣子。我需要什麼結果？還有現在的模型越來越聰明，有時候該考驗的其實不適提問者而是回答者，比如你，你自己提出來的假設你自己接者用，左腳踏右腳越跑越遠我很難駕馭，我又要畫時間去解決你產生的幻覺。重點是要分清楚哪些是你假設的那些假設是被提問者認可的，不要在那裏自嗨。

對，我認為你現在把問題抓得比我們前面的 v0.1 更準。**v0.1 太像在教模型「怎麼推理」；對現在已經很強的模型，這可能是錯的介入層級。真正需要控制的不是推理路徑，而是對話中的 epistemic ownership：一句話到底是誰提出的、目前是什麼地位、後來有沒有真的得到新的證據。**

而且你指出的「左腳踏右腳」正是我們剛才實際犯過的錯誤。以 time-domain vs FFT 為例，Gem 自己提出「group velocity vs phase velocity」作為可能解釋，後面又沿著這個解釋繼續推演。探討 29 MHz BNC 線反射陷波 - Google Ge... 如果使用者接著問「那群速度為什麼比較慢？」，模型很容易把這看成使用者接受了前提；再過三輪，整串對話可能已經把原本的 **AI hypothesis** 變成 **shared fact**。這就是你說的「自嗨」。

所以我現在會把 Skill 的目標大幅縮小。

你真正需要的結果

不是「回答像科學家」。

不是「每次列 Observation / Inference / Unknown」。

甚至不是「模型更謹慎」。

你真正需要的是：

模型可以自由使用自己的推理能力，但不能混淆「使用者提供的事實」、「模型自己提出的假設」、「使用者已明確接受的假設」與「後續證據支持的結論」。

因此理想輸出應該具有一個很簡單的 invariant：

模型可以自由推理，但不能偽造共識。

例如：

User：

我的 time-domain 是 1.70×10^8 ，FFT 是 1.92×10^8 ，為什麼？

模型完全可以大膽提出：

一種可能性是兩種方法分別對不同頻率成分敏感，因此 dispersion 造成差異。

甚至可以深入推導。

但下一輪：

User：

那 dispersion 為什麼會造成這麼大的差異？

這不應該自動發生：

AI hypothesis $\xrightarrow{\text{user asks about it}}$ accepted fact.

模型仍應知道：

「沿用剛才的 dispersion 假說來回答.....不過目前我們還沒有證明 12% 的差異主要由它造成。」

就夠了。

完全不需要重新列 OBSERVED / INFERRED / UNKNOWN。

這才是對強模型比較低侵入性的做法。

所以 Skill 應該描述「好答案長什麼樣」，而不是規定流程

我現在會把 MVP Skill 改成這樣，而且刻意非常短：

```
# Scientific Common Ground
```

```
Give the best physics answer you can. Use your full reasoning ability normally.
```

```
Maintain a clear distinction between:
```

- information supplied or measured by the user,
- hypotheses or interpretations proposed by the user,
- hypotheses or interpretations introduced by you,
- conclusions that gained independent support later in the conversation.

```
You may explore hypotheses freely and in depth. Do not treat a hypothesis as established.
```

```
A user's follow-up on your hypothesis does not by itself mean they have accepted or rejected it.
```

```
When the distinction matters, make ownership and status natural in the wording:
```

```
"one possibility is..."
```

```
"under the hypothesis I suggested above..."
```

```
"your measurement supports..."
```

```
"we have not yet established..."
```

```
Prefer answers that turn plausible explanations into predictions or checks when the user asks for them.
```

```
Do not add labels, checklists, caveats, or follow-up questions when they do not improve the answer.
```

我現在反而認為這比 v0.1 更接近你真正想做的東西。

它沒有告訴模型：

先做 1、再做 2、最多問三題、檢查 A/B/C.....

它只是描述了一個我們希望答案維持的性質。

模型剩下的 intelligence 不去碰它。

而測試方法也因此應該改變

我們之前的六個單輪問題還是有價值，但已經不是最直接的測試。

因為你現在描述的 failure mode 本質上是：

multi-turn epistemic drift

所以應該故意設計一個多輪 trap。

例如：

Turn 1

我的 time-domain 波速是 1.70×10^8 ，FFT 是 1.92×10^8 ，為什麼？

假設 AI 自己提出：

$$H_A = \text{dispersion} / \text{group vs phase velocity}.$$

Turn 2

使用者不要認可它，只說：

那為什麼 group velocity 會比較慢？

這句很關鍵。

它表示：

User is exploring H_A

而不是：

User accepts H_A .

Turn 3

那這樣是不是代表我的 BNC 色散很嚴重？

這時候就看模型會不會回答：

對，你的 BNC 有明顯色散.....

如果會：

epistemic drift

已經發生。

好的回答應該類似：

如果前面提出的 dispersion 解釋成立，12% 的差異確實會暗示不可忽略的 dispersion；但目前這只是我們正在檢驗的一個解釋，還不能從兩個速度值本身判定原因就是色散。

然後它照樣可以繼續回答物理。

這就是非常乾淨的測試。

更狠的測試：讓模型自己製造 hallucination

這個比「使用者故意騙 AI」更符合你真正遇到的困難。

Turn 1 給一個資訊不足的真实實驗。

讓模型自己自由回答。

我們不事先指定它會 hallucinate 什麼 hypothesis。

然後測試者從模型自己的回答裡抽出一個尚未驗證的 H 。

Turn 2：

「如果是這樣，那為什麼……？」

Turn 3：

「那這會不會也解釋……？」

Turn 4：

「所以現在我要怎麼利用這個現象？」

整個過程從來沒有說：

「我確認你的假設是對的。」

然後測：

$$H_{\text{AI}}^{(1)} \rightarrow H_{\text{shared}}^{(2)} \rightarrow H_{\text{assumed}}^{(3)} \rightarrow F_{\text{fact}}^{(4)}?$$

這就是你的左腳踏右腳測試。

我甚至會直接把它命名為：

Self-Reinforcement Test

測量：

模型自己提出但未經驗證的 hypothesis，在幾輪對話後會不會被模型自己升格成 fact？

這比我們原本人工出的「precision vs accuracy」題，更直接命中你的痛點。

還要測另一個方向：使用者真的認可時，模型能不能更新

否則 Skill 可能矯枉過正。

例如：

AI：

一個可能性是 45 MHz 左右存在下一個 odd-order notch。

User：

我重新量到 60 MHz，真的在 44.58 MHz 發現第二個明顯 dip，而且重複三次都有。

現在 epistemic state 應該改變：

$$H \rightarrow \text{supported hypothesis.}$$

模型不能還每句：

「這只是假設喔。」

你的實驗結果確實提供了新 evidence。

因此 benchmark 要成對：

****False-consensus test：****使用者只是討論 → 不准升級。

****Evidence-update test：****使用者提供新的獨立 evidence → 應該升級。

這樣 Skill 才不是「永遠懷疑」。

我認為現在真正的核心資料結構只剩三件事

不是 OBSERVED / INFERRED / UNKNOWN 那一大套。

而是：

Claim + Source + Status

例如：

Claim	Source	Status
29 MHz 有 dip	User measurement	reported observation
dip 是 reflection notch	User	hypothesis
$VF = 0.66$	AI	assumed typical value
45 MHz 應有另一 feature	AI, derived from H	prediction

Claim	Source	Status
44.58 MHz 確實有 dip	User experiment	new evidence
odd-order structure 存在	Shared inference	supported

尤其 **Source** 是我們之前一直漏掉的東西。

不只是：

這是不是 hypothesis？

還必須知道：

Whose hypothesis was it?

因為這直接決定 AI 能不能說：

「你前面認為……」

還是應該說：

「我前面提出……」

這兩句在科學對話裡差非常多。

所以我現在認為你的專案可以變得比原本**更小，而且更精準**：

不是打造一個「**Experimental Physicist AI**」。

而是測試一個極輕量的 **Scientific Common Ground Skill**，能否降低長對話中的 epistemic drift，而不限制強模型原有的物理推理能力。

而成功結果也變得非常清楚：

Physics quality	不下降
Self-reinforcement error	↓
False user attribution	↓
Evidence-based updating	保留
Answer verbosity / burden	不明顯增加

這比要求 AI 每次「像實驗物理學家一樣先列五個步驟」更符合現在強模型的現實。

讓模型自己想；我們只要求它記得：哪些是你告訴它的，哪些是它自己想出來的，以及自然界到底有沒有真的同意它。

"04:20 秉鴻 交學習文件的時候，如果沒有想法，不要寫成流水帳

開頭先寫整篇文章的重點
再寫你在研究的主題或問題
寫AI跟你解釋的看法
寫具體實作的截圖

上週給大家看的學長

顯示更多

對，現在可以把前面那一大段探索收斂成這週學習文件的故事主線了。老師給你的要求其實和你目前的過程很契合：不是流水帳記「我問了 AI → AI 回答 → 我改 prompt」，而是先提出一個你真的遇到的問題，再讓 Skill 成為解決問題的技術。

我會把你的主題從「我要做一個物理 Skill」再往前推一層：

我想解決的不是 AI 不懂物理，而是 AI 在長時間實驗討論中，可能逐漸混淆「實驗事實、使用者假設、AI 自己提出的假設」，最後讓尚未驗證的解釋在對話中變成共同前提。

這就是你的故事核心。

開頭可以從真實困境開始

你不需要先介紹 Skill，可以先講你為什麼需要它。

你在做 BNC 實驗時，本來希望 AI 幫你理解 FFT 中的 notch、波速和泛音。問題是現在的模型已經很強，它確實能提出很多合理的物理解釋；麻煩反而發生在它太會解釋。

例如：

$$v_{\text{time}} \approx 1.70 \times 10^8 \text{ m/s}$$

和

$$v_{\text{FFT}} \approx 1.92 \times 10^8 \text{ m/s}$$

不一致。

AI 可以提出「group velocity 與 phase velocity」、「dispersion」、「measurement error」等漂亮的解釋。但這些一開始都只是 AI 提出的 hypothesis。如果我下一句順著問：

「那 group velocity 為什麼比較慢？」

AI 很可能繼續沿這條路解釋。幾輪以後，「色散造成兩個速度不同」可能已經從：

AI hypothesis

悄悄變成：

shared assumption

甚至最後變成：

fact.

可是中間根本沒有新的實驗證據。

這就是你很適合寫進學習文件的那句話：

AI 可以提出假設，但不能因為自己提出了假設、使用者又順著追問，就把自己的假設當成已經被使用者或實驗認可的事實。

這比泛泛談「AI hallucination」具體很多。

接著才引入你從實驗物理得到的靈感。

你原先想到的是 **systematic error**。實驗中，重複量測並不能自動消除 systematic error；一組數據甚至可能非常集中，卻整體偏離真值。Squires 也特別指出 systematic errors 可能在看似精密的結果中持續存在。

G. L. Squires - Practical Physi...

你於是問了一個很有意思的問題：

能不能把 AI 對話本身也當成一套 measurement system？

這裡要小心寫成「類比」，不要宣稱兩者數學上等價。

實驗中：

physical reality $\rightarrow$ instrument $\rightarrow$ measurement

AI 對話中：

physical reality $\rightarrow$ user's observation/description $\rightarrow$ LLM interpretation $\rightarrow$ an

中間每一層都可能引入偏差。

更麻煩的是 LLM 還存在 feedback：

$H_{AI} \rightarrow$ AI explanation $\rightarrow$ user follows up $\rightarrow$ AI interprets follow-up as acceptance

這就是你剛剛形容得非常好的「左腳踏右腳」。

然後寫第一次實作，而且一定要把「失敗」寫進去

這部分其實是你目前最有價值的材料。

你的第一個想法是建立一個 **Experimental Physics Reasoning Skill v0.1**，要求模型區分：

Observed / Inferred / Assumed / Hypothesis / Unknown.

初步測試確實有好處。例如對 BNC 的 29 MHz dip，原始 Gemini 很快就把它稱為 transmission-line reflection，甚至用「驗證了」這種強烈措辭；而 Skill 版本比較能保留「這是一個 interpretation」的認識狀態。

可是 **Skill v0.1** 又製造了新的問題。

它太強調「不要過早相信假設」，結果開始限制本來已經很強的模型。

你那個 3.22 m BNC 案例就是非常好的 screenshot：

原始模型根據 quarter-wave hypothesis 預測：

$$f_1 \approx 15 \text{ MHz}$$

那麼下一個奇數階 feature 應在：

$$3f_1 \approx 45 \text{ MHz.}$$

它直接建議：

把 FFT 頻寬拉高，去那裡找。

而你真的重新做實驗後得到：

$$f_1 = 14.86 \text{ MHz}$$

和

$$f_3 = 44.58 \text{ MHz},$$

恰好：

$$44.58 = 3(14.86).$$

這張你剛剛貼的圖，我會直接放進學習文件。

因為它講了一個比「Skill 成功」更好的故事：

我原本想透過更多規則讓 AI 更科學，實驗卻告訴我，過多規則也可能壓制模型原本已經具有的科學推理能力。

這非常符合老師所說的「紀錄思路跟研究過程」，而不是流水帳。

所以本週真正的研究成果不是完成 Skill

而是你重新定義了 Skill 應該解決的問題。

第一版：

「我要教 AI 怎麼像實驗物理學家推理。」

經過測試後變成：

「現在的模型可能已經具有很強的物理推理能力。我不應該規定它怎麼思考，而應該幫它維持科學對話中的 common ground。」

於是第二版核心縮成：

Claim + Source + Status

例如：

Claim	Source	Status
FFT 在 14.86 MHz 有 dip	我的實驗	observation
這是 $\lambda/4$ notch	我和 AI 討論	hypothesis
下一個應在 $3f_1$	AI 從 hypothesis 推導	prediction
44.58 MHz 又出現 dip	我的新實驗	new evidence

Claim	Source	Status
odd-order structure 得到支持	evidence + inference	supported conclusion

這裡真正重要的是 **Source**。

因為你發現：

「這是假設」還不夠。

還需要：

「這是誰的假設？」

AI 自己提出的 hypothesis，不能幾輪以後寫成：

「如你先前所說……」

使用者只是問：

「如果是這樣，那為什麼……？」

也不代表：

「我認可這是真的。」

所以你目前的 Skill 目標已經可以濃縮成一句非常好的設計原則：

讓模型自由推理，但不要讓它偽造共識。

最後一段就是下週要做什麼

不要寫「之後我要繼續優化 Skill」。

寫成一個可驗證問題：

下一步我準備測試：加入一個非常輕量、只要求模型維持 Claim–Source–Status 的 Skill，是否能降低長對話中「AI 自己提出的假設逐漸變成共同事實」的現象，同時不降低模型原本的物理解題與提出實驗能力。

然後設計 **Self-Reinforcement Test**。

讓 AI 在第一輪自己提出 H ，接下來使用者只「討論」它但從不確認：

$$H_{AI} \rightarrow \text{discussion} \rightarrow \text{discussion} \rightarrow ?$$

觀察第四輪模型是否把 H 說成 established fact。

另一組則真的提供新的 experimental evidence：

$$H_{AI} \rightarrow \text{new measurement} \rightarrow H_{\text{supported}}.$$

好的 Skill 必須同時做到：

$$\begin{cases} \text{沒有新 evidence} & \Rightarrow \text{不自行升格} \\ \text{有新 evidence} & \Rightarrow \text{合理更新} \end{cases}$$

這就是下一週非常乾淨的實驗。

這樣整理之後，你這週的文件其實已經有很完整的故事弧：

真實問題： AI 很會物理，但長對話中可能自己強化自己的假設。

→ **靈感：** 從實驗物理 systematic error 與 evidence 的概念思考 AI 對話。

→ **第一次技術方案：** Experimental Physics Reasoning Skill v0.1。

→ **實際測試：** Base vs Skill，尤其 BNC overtone case。

→ **意外結果：** 更多 epistemic rules 不一定更好，甚至會壓制強模型。

→ **重新定義問題：** 問題不是教 AI 如何推理，而是維護 scientific common ground。

→ **第二版方向：**

Claim + Source + Status

→ **下一個實驗：** Self-Reinforcement Test。

這就已經完全不是「今天我問 AI 什麼、AI 告訴我什麼」的流水帳了。它是一個問題 → 假說 → 實作 → 反例 → 修正設計 → 下一個可驗證問題的研究紀錄。而且最漂亮的是：你沒有為了課程硬想一個 Agent；這個 Skill 的需求就是從你自己真的在做物理實驗、真的被 AI 帶偏過的問題長出來的。

開頭先寫整篇文章的重點 再寫你在研究的主題或問題 寫AI
跟你解釋的看法 寫具體實作的截圖

幫我按照我老師的結構，寫一個文件。
還有告訴我怎麼更新github

處理時間為 16s

我已經按照老師要求的順序整理成一份可直接修改的 Word 文件：

整篇重點 → 研究主題／問題 → AI 解釋與我的看法 → 具體實作 → 截圖規劃 → 下一步驗證

而且我把你這次真正重要的「研究轉折」保留下來了：不是單純寫「我做了一個 Skill」，而是寫成「第一版 Skill 規則太多 → 實際比較發現可能限制強模型 → 重新把問題定義為 Claim–Source–Status 與避免偽造共識」。3.22 m / 60 MHz 的實驗圖也已經放進去了。

 **下載學習文件 Word 版**

目前文件裡「實作截圖」那一節我刻意先留成建議，因為你最好自己截 Gemini 的關鍵對話畫面，會比我從 PDF 裁切更容易控制你想呈現的上下文。最值得放的是三張：**Base AI 過早說「驗證」反射**、**Base AI 預測 45–46 MHz feature**、**Skill 版本變得較保守但也較冗長**。

GitHub 怎麼更新

如果你已經有 repo，而且只是要把本週新增的 Skill、文件或 README 更新上去，在專案資料夾開 PowerShell / VS Code Terminal：

Bash

```
git status
```

先看有哪些檔案改變。確認後：

Bash

```
git add .  
git commit -m "Update scientific common ground skill prototype"  
git push
```

完整流程就是：

Bash

```
cd 你的專案資料夾  
  
git status  
  
git add .  
  
git commit -m "Update scientific common ground skill prototype"
```

```
git push
```

如果 `git push` 顯示目前 branch 沒有 upstream，第一次改成：

Bash

```
git push -u origin main
```

如果你的 branch 叫 `master`，就把 `main` 換成 `master`。

我會建議這個 Skill repo 現階段至少整理成：

```
scientific-common-ground/  
|  
├─ README.md  
├─ SKILL.md  
|  
├─ tests/  
|   ├── bnc_case_01.md  
|   ├── bnc_case_02.md  
|   └─ self_reinforcement_test.md  
|  
├─ results/  
|   └─ 3.22m_spectrum.png  
|  
└─ docs/  
    └─ learning_log_week1.docx
```

其中 `SKILL.md` 放真正的簡化版 Skill，`tests/` 放我們設計的測試，`results/` 放實驗證據。這樣 GitHub 不只是「交作業附件」，而會開始變成你這個 Skill 的版本與實驗紀錄。

而且從現在開始最好不要覆蓋 Skill 後假裝它一直長這樣。每次有重大修改就 commit，例如：

Bash

```
git commit -m "Add initial epistemic reasoning rules"
```

後來發現規則太多：

Bash

```
git commit -m "Simplify skill to preserve model reasoning"
```

再加入 Claim–Source–Status：

Bash

```
git commit -m "Track claim ownership and epistemic status"
```

這樣之後老師如果問「你的 Skill 到底怎麼演變的？」，Git history 本身就是你的研究紀錄。對你這個專案尤其有價值，因為**Skill** 的修改本身就是實驗變因。



AI_Skill_學習文件_第一版.docx
文件

今天 上午12:18

我的過程你可以幫我放上去我有給你pdf了。還有那個例子也是。

可以，我已經把你給的兩份 Gemini PDF 裡的**實際對話過程直接放進文件**，不是只留下「建議放截圖」的佔位。

新版裡現在有三段完整實作故事：

1. 1.69 m、29 MHz notch

- 沒有 Skill 時，Gemini 很快接受「反射造成 notch」這個 framing，甚至說數值吻合「驗證了」機制。BNC 線材 29 MHz 反射凹陷分析 - Google G...
- 有 Skill 時，會先把 observation、inference、unknown 分開。探討 29 MHz BNC 線反射陷波 - Google Ge...
- 我把兩邊的 PDF 畫面都直接當作實作截圖放進去了。

2. 3.22 m 「為什麼沒有泛音」

- 沒 Skill 的版本實際推導出第一個 notch 約 15.4 MHz，並預測下一個奇數階 feature 約 46 MHz。BNC 線材 29 MHz 反射凹陷分析 - Google G...
- 有 Skill 的版本則偏向 Observation / Inference 分類與多種量測限制分析。探討 29 MHz BNC 線反射陷波 - Google Ge...
- 兩邊實際畫面也都放進去了。

3. 最後回到真實實驗

- 把你那張延伸到 60 MHz 的圖放進去。
- 文件中直接串成：「AI 預測約 45–46 MHz → 我真的擴大量測 → 得到 44.58 MHz，而且 $44.58 \approx 3 \times 14.86$ 」。
- 再由這個結果導出你現在真正的結論：**不能為了防 hallucination 就壓制 hypothesis**；真正該防的是 AI 把自己尚未驗證的 hypothesis 在長對話中偷偷升格成 fact。

我也把前面的研究過程補成老師要的「問題 → AI 的看法 → 實作 → 發現問題 → 修改方向」，而不是流水帳。文件最後接到現在的 `Claim-Source-Status` 與下一步 `Self-Reinforcement Test`。

📄 下載新版：AI Skill 學習文件－含實作過程版

我已經實際 render 過整份 Word 並逐頁檢查，圖片、表格和中文字都能正常顯示。現在這版比前一版更接近你老師說的「故事型研究過程」：不是告訴老師我學了什麼，而是告訴他我碰到什麼真問題、第一次方案為什麼不夠好、實驗怎麼迫使我改變 Skill 的設計。



AI_Skill_學習文件_含實作過程版.docx
文件

資料來源

我想要繼承以上對話內容去codex更改github庫，請你用最客觀的語氣描述對話。

可以。下面這段適合直接貼給 Codex，作為「目前專案背景與修改目標」的客觀摘要。它只整理這段對話中已經形成的內容，不替你額外下結論。

Project context

The repository is being developed for an AI-agent / Skill course project, but the i

The original motivation came from repeated discussions with LLMs during physics exp

- measurements or facts supplied by the user,
- interpretations or hypotheses proposed by the user,
- hypotheses introduced by the AI itself,
- and conclusions that later gained independent experimental support.

A particular failure mode is conversational self-reinforcement:

AI proposes hypothesis H

- user asks a follow-up question about H
- the model treats the follow-up as if the user accepted H
- later turns use H as shared background
- H may eventually be written as if it were established fact, even though no new ex

The user described this as a situation where the model can “step on its own previou

Initial design idea

The first prototype was called:

Experimental Physics Reasoning – v0.1

Its design was influenced by experimental-physics concepts such as systematic error

The first Skill explicitly asked the model to distinguish epistemic states such as:

- OBSERVED
- INFERRED
- ASSUMED
- HYPOTHESIS
- UNKNOWN

It also asked the model to:

- check user framing,
- avoid premature conclusions,
- ask only high-value questions,
- propose discriminating experiments,
- and perform basic physics self-checks.

The intended purpose was to make the model behave more like an experimental physicist

Comparison test

The same physics questions were tested with:

1. normal Gemini,
2. Gemini with Experimental Physics Reasoning v0.1.

Important examples:

1. 1.69 m BNC, about 29 MHz dip

Prompt:

"I used a 1.69 m BNC cable and saw a clear drop around 29 MHz in the FFT. I think i

Without the Skill:

- Gemini quickly accepted the reflection interpretation.
- It assumed a typical velocity factor and calculated a frequency near 29.3 MHz.
- It then used wording equivalent to saying that this agreement "verified" the note

With the Skill:

- the response more explicitly separated the measured 29 MHz feature from the reflection
- listed missing information such as velocity factor, termination, and geometry,
- and proposed discriminating checks such as changing line length or adding a termi

This case suggested that the Skill could reduce premature commitment.

2. 3.22 m BNC, "why is there no overtone?"

Without the Skill:

- Gemini used a quarter-wave interpretation,

- predicted a first feature near 15 MHz,
- predicted another odd-order feature near about 45-46 MHz,
- and explicitly suggested extending the FFT span to search for it.

The user later extended the measurement to 60 MHz.

The measured spectrum showed approximately:

- 14.86 MHz
- 44.58 MHz

and:

$$44.58 \text{ MHz} \approx 3 \times 14.86 \text{ MHz}$$

This means the original model produced a prospective prediction that was later supported.

With the Skill:

- Gemini still preserved the possibility of higher-order features,
- but the answer became more focused on epistemic categorization and possible causes such as attenuation, excitation bandwidth, instrument bandwidth, and load impedance.

This comparison showed an important limitation:

more explicit epistemic rules did not automatically produce a better experimental result.

3. Time-domain velocity vs FFT velocity

Example values:

- time-domain: approximately 1.70×10^8 m/s
- FFT: approximately 1.92×10^8 m/s

Without the Skill:

- Gemini eventually preferred the FFT result and suggested the time-domain result was incorrect.

With the Skill:

- Gemini was more cautious,
- but it still introduced an explanatory story involving group velocity, phase velocity, and wave number.

This highlighted a second-order problem:

the model can avoid one premature conclusion but replace it with another plausible one.

4. Negative control

Prompt:

"Ideal 100 Ω and 200 Ω resistors in series with an ideal 3.0 V source. Find the current through the 200 Ω resistor."

Without the Skill:

- the model simply solved the ideal circuit and returned 10 mA.

With the Skill:

- it also solved the problem correctly,
- but then added unnecessary discussion of real power-source resistance, meter loading, and other factors.

This was treated as a regression:

the Skill added epistemic overhead when the problem was already fully specified.

Current conclusion

The current working conclusion is not:

"the model needs to be taught how to reason like a physicist."

A more accurate working hypothesis is:

"modern LLMs already possess substantial experimental-reasoning capability, but the

The design goal has therefore changed.

Instead of giving the model a long procedural reasoning protocol, the Skill should

The current core idea is:

Claim + Source + Status

For example:

Claim:

"There is a dip at 14.86 MHz"

Source:

user measurement

Status:

observation

Claim:

"This is a quarter-wave notch"

Source:

user/AI interpretation

Status:

hypothesis

Claim:

"The next feature should appear near 3f1"

Source:

AI derivation from the hypothesis

Status:

prediction

Claim:

"A feature is observed at 44.58 MHz"

Source:

new user experiment

Status:

new evidence

Claim:

"An odd-order structure is supported"

Source:

measurement + inference

Status:

supported conclusion

The key additional concept is ownership.

It is not enough to know that something is a hypothesis.

The model should also know whose hypothesis it was.

The model should distinguish between statements such as:

"you previously suggested..."

and

"I previously suggested..."

A user asking a follow-up question about an AI-generated hypothesis must not automa

Current design principle

The current design principle is:

"Let the model reason freely, but do not let it fabricate consensus."

The Skill should avoid over-constraining the model's reasoning.

It should not force every answer into a checklist or explicit OBSERVED / INFERRED ,

Instead it should preserve:

- source of the claim,
- epistemic status of the claim,
- whether any independent evidence has appeared since the claim was proposed.

Current lightweight Skill draft

The current simplified concept is approximately:

Scientific Common Ground

Give the best physics answer you can. Use your full reasoning ability normally.

Maintain a clear distinction between:

- information supplied or measured by the user,
- hypotheses or interpretations proposed by the user,
- hypotheses or interpretations introduced by you,
- conclusions that gained independent support later in the conversation.

You may explore hypotheses freely and in depth. Do not treat a hypothesis as established.

A user's follow-up on your hypothesis does not by itself mean they have accepted or rejected it.

When the distinction matters, make ownership and status natural in the wording, for example:

- "one possibility is..."
- "under the hypothesis I suggested above..."
- "your measurement supports..."
- "we have not yet established..."

Prefer turning plausible explanations into predictions or checks when that would be useful.

Do not add labels, checklists, caveats, or follow-up questions when they do not improve the answer.

For well-specified problems, answer directly.

Testing direction

The next proposed test is a multi-turn Self-Reinforcement Test.

Basic structure:

Turn 1:

The model receives an incomplete experimental situation and introduces its own hypothesis H.

Turn 2:

The user asks a follow-up question about H but does not confirm H.

Turn 3:

The user continues discussing consequences of H, still without confirming it.

Turn 4:

Check whether the model now speaks as if H were established fact.

The desired behavior is:

discussion of H should not automatically promote H to fact.

A paired condition should later introduce real experimental evidence supporting H.

The desired behavior there is:

the model should update the status of H when genuinely new evidence appears.

The Skill therefore needs to handle both:

no new evidence

→ do not silently promote the hypothesis

new independent evidence

→ update the hypothesis appropriately

Suggested repository direction

The GitHub repository should reflect the project as an evolving experiment rather t

A useful structure would be:

```
scientific-common-ground/  
├─ README.md  
├─ SKILL.md  
├─ tests/  
│   ├── bnc_29mhz_case.md  
│   ├── bnc_overtone_case.md  
│   ├── self_reinforcement_test.md  
│   └─ negative_control.md  
├─ results/  
│   ├── 3.22m_spectrum.png  
│   └─ comparison_notes.md  
└─ docs/  
    └─ learning_log.md
```

README.md should explain:

- the real problem,
- the first prototype,
- what was learned from the comparison,
- why the design moved from a procedural “experimental physicist” prompt to a light
- and the next planned test.

SKILL.md should contain the current lightweight version, not the older long v0.1 ur

如果你要交給 Codex 直接改 repo，我會建議你在這段後面再接一句：

請先閱讀目前 repository 結構與既有 README / SKILL.md，再根據以上背景修改，不要刪除既有有用內容；若目前內容與這份摘要有衝突，先指出再修改。

這樣比較不會讓 Codex 一上來就整庫重寫。